

[수치해석] Eigen vector / value

Eigen vector / value

Spectrum: Eigen value의 집합

$$Ax = \lambda x$$

- x : Eigen vector
- λ : Eigen value

위 식을 변형하면 아래와 같다.

$$(A - \lambda I)x = 0$$

- $\det(A - \lambda I) \neq 0 \rightarrow$ Trival solution: $x = 0$
 - $(A - \lambda I)(A - \lambda I)^{-1}x = 0 \rightarrow x = 0$
- $\det(A - \lambda I) = 0 \rightarrow$ Non-trival solution: $x \neq 0$
 - Eigen vector는 0이 아닌 벡터이기 때문에 Non-trival solution을 찾아야 한다.

Characteristic equation

$$\det(A - \lambda I) = 0$$

- 이 방정식을 풀면 Eigen value의 집합인 **Specturm**을 구할 수 있다.

Eigen value의 성질

1. $A = \sum_{i=1}^n a_{ii} = \sum_{i=1}^n \lambda_i$

2. $\det A = \sum_{i=1}^n \lambda_i$

3. A가 대칭 행렬이라면, **Eigenvector**는 서로 **Orthogonal**하다.

- $x_i^T x_j = 0$ ($i \neq j$)
- $x_i^T x_i = \|x_i\|^2$ ($i = j$)

4. A의 Eigen value를 $\lambda_1, \lambda_2, \dots, \lambda_n$ 이라고 할 때, $(A - aI)$ 의 Eigen value는 $\lambda_1 - a, \lambda_2 - a, \dots, \lambda_n - a$ 이다.

- a는 임의의 스칼라 값이다.
- **Exploiting shifting property**라고 부른다.

Eigen vector의 기하학적 해석

1. $Ax = \lambda x$ 에서 A 행렬은 **Eigen vector**의 방향은 유지한 채, 크기만 변경한다.

2. A가 대칭 행렬이라면, Eigen vector들을 서로 Orthogonal하다.

- 대칭 행렬은 원래 Ax 에서 x의 차원 축을 뭉개지 않는다.
 - $x_{12} = x_{21}$ 이라는 것은 1번이 2번에 주는 영향과 2번이 1번에 주는 영향이 동일하기 때문이라고 생각하면 된다.
- 대칭 행렬 A를 이용해 $Ax = \lambda x$ 를 통해 Eigen vector를 얻었더니 전부 Orthogonal 했다.

3. A가 Singular matrix라면 $\det(A) = 0$ 이기 때문에 **최소한 하나의 Eigen value는 0**이다.

- $\det A = \sum_{i=1}^n \lambda_i = 0$

SVD와 Eigen value decomposition

$$A = U\Sigma V^\top$$

- 이를 변형하면 $Av = \sigma u$ 이다.
- 이때 Row-Orthogonal space V 에서 Column-Orthogonal space U 로 변하도록 만드는 것이라고 생각하면 된다.
- SVD는 정방 행렬이 아니여도 가능하다.

A 가 대칭 행렬 ($N \times N$)이라면, $U = V$ 가 되어 **SVD와 Eigen value decomposition이 동일해진다.**

$$A = Q\Sigma Q^\top$$

- 때문에, 대칭 행렬인 경우 **서로 다른 Eigen vector가 Orthogonal**이다.
- Eigen value decomposition은 정방 행렬인 경우에만 사용 가능하다.

Similar matrix

두 개의 $N \times N$ 행렬 A, B 에 대해 $A = S^{-1}BS$ 를 만족하는 행렬 S 가 존재한다면 두 행렬이 **Similar**하다.

Eigen vector에 따르면 다음과 같다.

1. $Ax = \lambda x = S^{-1}BSx$
2. $\lambda Sx = BSx$
3. x 가 0이 아니고 S 가 Singular matrix가 아니라면 (2)의 식이 성립하기 위해선 B 의 **Eigen value**가 λ 여야 한다.
4. 따라서 BSx 가 Eigen vector, λ 가 Eigen value이다.

A와 B가 Similar matrix이면, 두 행렬의 Eigen value가 동일하다.

- 아래에서 “좌표계를 변경해도 고유값은 동일하다”라는 것을 확인할 수 있다.

EX) Rotation matrix

좌표 변환 (Coordinate transformation)

우리가 일반적으로 아는 X, Y 좌표계에서의 (3, 1) 벡터를 생각해보자.

- 이때의 Basis는 $[1 \ 0]$, $[0 \ 1]$ 이다.

다른 Basis로 변화시켜보자.

- $b_1 = [1 \ 1]$, $b_2 = [-1 \ 1]$ 로 변화시키고자 해보자.

(3, 1) 벡터의 방향은 동일하지만, 숫자로는 다르게 표현되어야 한다.

- 기존 (3, 1)은 $3[1 \ 0] + 1[0 \ 1]$ 이다.
- Basis가 바뀌었기 때문에 $c_1, c_2 = c_1[1 \ 1] + c_2[-1 \ 1]$ 로 나타나야 한다.
 - 이를 구하면 (2, -1)이다.

이렇게 좌표계 자체가 변하는 것을 **Coordinate transformation**이라고 한다.

- R은 좌표계를 회전 시키는 경우의 Coordinate transformation은 다음과 같이 쓸 수 있다.
- $X' = RX, Y' = RY$

Similarity transformation

그럼 위 Rotation을 이용한 Coordinate transformation을 Similarity transformation으로 표현해보자.

$y = Ax$ 인 좌표계에서 $y' = Ry$ 로 회전시키는 상황을 고려하자.

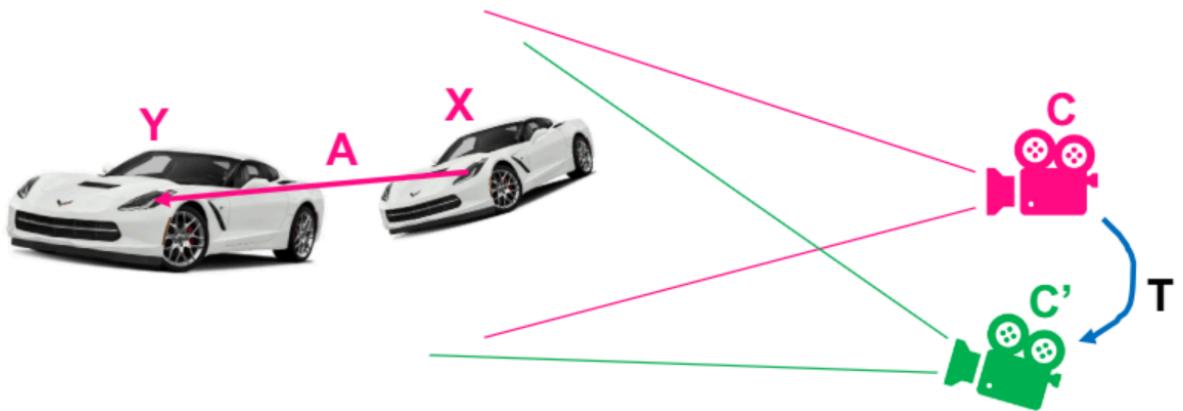
1. $y' = Ry = RAx$ 이다.
2. x 도 새로운 좌표계에서 표현하면 $x' = Rx$ 이다.

- 1번 식에 대입하기 위해 $x = R^{-1}x$ 를 사용하자.

3. (1) 식에 $x = R^{-1}x$ 를 대입하면 $y' = RAR^{-1}x = Bx$ 이다.

- $B = RAR^{-1}$ 일 때, B와 A는 Similar matrix이다.
- 원래 좌표계에서 A라는 변환이 회전한 좌표계에선 B처럼 보이는 것이다.
 - 둘은 한 벡터를 동일하게 변환하는 행렬이고 좌표계가 달라 표현만 다른 것이다.
 - **변환이 동일하기 때문에 Eigen value가 동일하다.**
 - 좌표계가 변경되어도 고유값은 동일하다.
 - 변화량 자체는 동일하다.

Example: Computer Graphics



카메라가 원래의 위치 C 에서 C' 으로 이동하고 이 이동을 T 라고 하자.

자동차는 X 에서 Y 로 이동하며 그 이동은 A 라고 한다.

위 상황에서 아래 식을 도출할 수 있다.

- $Y = AX$
- $C' = TC$
- $X' = TX$

- $Y' = TY$

이때, C' 카메라에서 보이는 차의 이동을 B 로 표현해보자.

- $Y' = BX'$

B 를 구해보자.

1. $Y' = TY$ 에 $Y = AX$ 을 대입한다,

- $Y' = TAX$

2. $Y' = TAX$ 에 $X = T^{-1}X'$ 을 대입한다.

- $Y' = TAT^{-1}X'$

3. 따라서 $B = TAT^{-1}$ 이다.

Numerical methods

$\det(A - \lambda I) = 0$ 을 계산하는 방법에는 한계가 있기 때문에 대신 사용하는 Eigen value를 찾는 방법

1. Power method

절댓값이 가장 큰 Eigen value를 찾는 방법

$$Ax^{(k)} = y^{(k+1)} = \lambda^{(k+1)}x^{(k+1)}$$

과정

1. Ax 를 구한다.
2. Ax 의 결과로 부터 단위성분을 만든다.

- $c[\text{vector}]$ 형태가 된다.
 - Vector의 전체 성분 중 절댓값이 가장 큰 것으로 나눈다.
3. (2)에서 c 가 Eigen value, [vector]가 Eigen vector가 된다.
 4. (3)에서의 Eigen vector를 x 로 하여 (1) ~ (3) 과정을 반복한다.
 5. 수렴했을 때의 Eigen value와 Eigen vector가 가장 큰 Eigen value와 그에 해당하는 Eigen vector이다.

2. Inverse method

| 절댓값이 가장 작은 Eigen value를 찾는 방법

$$A^{-1}x^{(k)} = y^{(k+1)} \Leftrightarrow Ay^{(k+1)} = x \Leftrightarrow Lc = x^{(k)}, Uy^{(k+1)} = c$$

LU 분해를 이용하여 $A^{-1}x$ 를 계산하는 것 제외하면 Power method와 동일하다.

Exploiting shifting property를 이용하면, $(A - \lambda I)$ 의 Eigen value가 $\lambda - a$ 가 되는 것을 알기 때문에,

$(A - \lambda I)$ 의 가장 크거나 작은 Eigen value를 찾도록 해서 A의 중간 정도 크기의 Eigen value를 얻을 수도 있다.

추가로, Power Method는 "1등 고유값"과 "2등 고유값"의 차이가 클수록 수렴 속도가 빨라지는데, Exploiting shifting property를 통해 차이를 크게 만들어 수렴 속도를 높일 수 있다.

3. Deflation method

| Power method를 통해 가장 큰 Eigen value를 찾았을 때, 이미 찾은 Eigen value의 영향을 제거해서 다시 Power method를 통해 다음으로 큰 Eigen value를 찾도록 반복하는 방법

$\lambda_1, \lambda_2, \dots, \lambda_n, v^{(1)}, v^{(2)}, \dots, v^{(n)}$ 이 있을 때, λ_1 이 가장 크다는 것을 이미 안다고 가정하자.

Deflated matrix $B = A - \lambda_1 v^{(1)} x^T$ 를 만든다.

- $x^T v^{(1)} = 1$ 이어야 한다.
 - 이를 만족하는 x 를 적절히 선택해야 한다.
- 양변에 $v^{(1)}$ 을 곱해보면 B에서의 $v^{(1)}$ 에 대응되는 Eigen value가 0임을 확인할 수 있다.
- Eigen values = $0, \lambda_2, \lambda_3, \dots, \lambda_n$
 - 고유값은 동일하다.
- Eigen vectors = $v^{(1)}, w^{(2)}, w^{(3)}, \dots, w^{(n)}$
- A의 고유 벡터와 B의 고유 벡터의 관계식: $v^{(i)} = (\lambda_i - \lambda_1)w^{(i)} + \lambda_1(x^T w^{(i)})v^{(1)}$

이제 B에서 Power method를 진행하면 두 번째로 큰 Eigen value를 얻을 수 있다.

- Power method 또는 직접 Eigen value를 구할 수도 있다.
- B에서 제거한 Eigen value에 해당하는 열과 행은 지우고 Eigen value를 구하면 된다.
- $w^{(2)}$ 를 얻고, 위 관계식을 통해 $v^{(2)}$ 를 얻으면 된다.

Hotelling's Deflation Method

$$A_{i+1} = A_i - \lambda_i v_i v_i^T$$

- 직전 행렬을 통해 구한 가장 큰 고유값 / 고유 벡터를 이용하여 다음 행렬을 계산한다.
- 각 행렬에 대해 Power method를 반복한다.
- Eigen vector가 Orthogonal하면 Eigen value decomposition가 깔끔하기 때문에 Symmetric matrix A에 대해서만 가능하다.

Eigen value decomposition

$$A = \lambda_1 v_1 v_1^T + \lambda_2 v_2 v_2^T + \cdots + \lambda_n v_n v_n^T$$

- 위 공식을 사용하는 이유이다.

4. Jacobi Transformation

| 대칭 행렬에서 대각 원소만 남겨 Eigen value를 얻고자 하는 방법

과정

1. 행렬 A에서 가장 큰 Off-diagonal 원소를 찾아, 해당 원소를 0으로 만들 수 있는 Rotation matrix P 를 찾는다.
2. $A_{new} = P^T AP$ 를 얻는다.
3. A_{new} 가 diagonal element만 가질 때까지 위 과정을 반복한다.

Rotation은 Similarity transformation이기 때문에 Eigen value가 변하지 않아서 가능한 방법이다.

최종 Diagonal matrix의 각 Element가 해당 방향의 Eigen value이다.